

Semantic News Novelty — Q&A шпаргалка с цифрами

1. Качество модели / польза

Блок	Было	Стало	Что сказать
Повторы в Top-10	—	-75%	В выдаче стало заметно меньше повторов
MRR@10	0.91	0.99	Поиск по смыслу лучше поднимает нужные новости
Recall обновлений	0.51	0.99	Главное — не пропускать важные обновления
F1 обновлений	0.63	0.91	Баланс качества сильно вырос
Recall сюжетов	0.63	0.83	Лучше находятся связи внутри сюжетов
F1 сюжетов	0.77	0.90	Группировка стала устойчивее
False merge rate	—	1.89%	Ложные склейки низкие

Короткий ответ:

Оптимизировал под задачу аналитика: лучше показать лишнее спорное обновление, чем скрыть важное.

2. GPU-производительность

Тест	Время	Скорость	Комментарий
Demo 250, full warm	8.77 с	28.52/с	Маленький прогретый сценарий
10k, full warm Docker	226.33 с	44.18/с	Основной быстрый режим
10k, incremental	697.71 с	14.33/с	Медленнее из-за растущей истории
50k, HTTP import	114.42 с	—	Загрузка данных
50k, full pipeline	1237 с / 20.6 мин	40.42/с	Скорость почти не просела
50k, embedding phase	14:27	—	Основная тяжёлая часть
50k, batches	3125	—	Batch size 16
50k, кластеры	46 412	—	Большинство новостей одиночные
50k, рёбра похожести	4429	—	Связи похожих публикаций

Короткий ответ:

Проверил 50 тысяч новостей: full pipeline занял около 20 минут, скорость — примерно 40 новостей/с.

3. Ресурсы на 50k

Ресурс	Peak	Avg	Вывод
GPU utilization	100%	78%	GPU реально работает
VRAM RTX 4070	8.33 GiB	8.23 GiB	Не упёрлись в 12 GB
model-service CPU	3.92 cores	1.03 cores	CPU не главный лимит
model-service RAM	4.85 GiB	2.21 GiB	RAM не ограничивает
PostgreSQL CPU	0.95 cores	0.16 cores	БД не узкое место
PostgreSQL RAM	1.03 GiB	0.55 GiB	Нормально
API CPU	0.27 cores	0.05 cores	API лёгкий
API RAM	0.38 GiB	0.37 GiB	Нормально
RabbitMQ CPU	7.47 cores	1.23 cores	Пики есть, но job прошёл
RabbitMQ RAM	0.27 GiB	0.21 GiB	Очередь по памяти лёгкая

Короткий ответ:

Память не стала ограничением: VRAM peak 8.33 GB из 12 GB, RAM model-service peak 4.85 GB. Ограничитель — GPU по скорости.

4. Таймауты и batch

Вопрос	Факт	Что сказать
50k прошли?	Да, 50k requested / 50k updated	Объём обработался полностью
nginx 504 был?	Да, до настройки timeout	Backend успевал закоммитить, nginx возвращал 504
Что изменено?	<code>proxy_send_timeout</code> , <code>proxy_read_timeout</code> → 600 c	Это закрывает ближайший сценарий
RabbitMQ timeout на 50k?	Новых timeout не было	На успешном 50k job очередь отработала
Почему нужен batch?	Один длинный job плохо управляется	Batch нужен для retry, прогресса и обхода таймаутов
ZIP нужен зачем?	CSV/ZIP импорт	Удобнее крупные выгрузки, меньше проблем с HTTP

Короткий ответ:

50k уже проходят. Batch нужен не из-за памяти, а из-за production-устойчивости: retry, прогресс, восстановление и таймауты.

5. CPU-режим

Конфигурация	Объём	Время	Скорость	Вывод
1 CPU-контейнер	1000	465.51 с	2.15/с	Работает, но медленно
4 CPU-контейнера	4×250	407.19 с	2.46/с	Только 1.14× ускорение
CPU 10k	10k	>30 мин	—	Превысил RabbitMQ ack timeout

Короткий ответ:

CPU-режим возможен для малых объёмов, но для больших импортов GPU намного предпочтительнее: 2–2.5/с против 40+/с.

6. Incremental vs full

Метрика	Последняя точка replay
Объём replay	3176 публикаций
Период	47 дней
Pairwise F1	0.836
Recall	0.859
Fragmentation	10.8%
Согласованность новизны	98.1%
Политика	full reclustering раз в 2 недели

Короткий ответ:

Incremental нужен для текущей работы, но ошибки структуры кластеров накапливаются. Поэтому нужен периодический full reclustering.

7. Своя монетизация

Модель	Цена-гипотеза	Инфраструктура	Ограничения	Для кого
Подписка	15–25 тыс. ₽/мес за организацию	Наша	Лимиты/кредиты на загрузку	Малые команды, быстрый старт
Лицензия / on-premise	300–600 тыс. ₽/год за инстанс	Клиента	Без кредитов в рамках стенда	Клиенты с требованиями к данным

Короткий ответ:

Подписка — hosted-сервис с лимитами. Лицензия — on-premise: клиент даёт оборудование, мы разворачиваем и сопровождаем стенд.

8. Цены конкурентов / ориентиры

Решение	Ориентир цены	Как позиционировать
Медиалогия SM	22–105 тыс. ₽/мес	Российский full-cycle ориентир снизу
Feedly Market Intelligence	\$1,600–2,400/мес	Западный upper-market ориентир
NewsWhip	\$2,000/user/month	Осторожно: цена из Capterra, не официальный прайс
SNN подписка	15–25 тыс. ₽/мес	Уже и дешевле: постобработка потока
SNN лицензия	300–600 тыс. ₽/год	On-premise, данные у клиента

Короткий ответ:

SNN не заменяет full-cycle мониторинг. Это более узкий и дешёвый слой: сюжеты, новизна, поиск и редакторский контроль поверх уже собранного потока.

9. Готовые ответы в 1 строку

Вопрос	Ответ
Сколько обрабатывает?	Проверено 50k новостей , full pipeline 1237 с , около 40/с
Уперлись в память?	Нет: VRAM 8.33/12 GB , RAM model-service 4.85 GB
Что ограничивает?	GPU по скорости, не память и не БД
Почему batch нужен?	Для retry, прогресса, восстановления и таймаутов
CPU хватит?	Для малых объёмов да; для больших GPU лучше: 2.5/с vs 40/с
Почему не ChatGPT?	Нет ролей, истории, поиска по базе, контроля меток и on-premise
Почему не Медиалогия?	SNN уже: не full-cycle мониторинг, а постобработка потока
Цена подтверждена?	Нет, это гипотеза для пилота
Главный риск?	Мало ручной разметки и нет пилота с клиентом
Что уже не просто модель?	UI, API, очередь, БД+pgvector, роли, организации, мониторинг
Что следующее?	Больше разметки, batch, улучшение названий, RSS/API, пилот