

Памятка для ответов на вопросы по Semantic News Novelty

Общая позиция

Semantic News Novelty — это учебный инженерный ML-прототип продукта для аналитиков новостного потока.

Я проверил техническую гипотезу: можно ли сгруппировать новости в сюжеты, выделить смысловую новизну и обернуть это в работающий сервис.

Важно честно разделять:

- что уже сделано: модель, метрики, сервис, роли, очередь, UI, мониторинг;
- что ещё не проверено: реальные клиенты, свежий доменный поток, большая ручная разметка, коммерческая готовность платить.

1. Почему BGE-M3?

BGE-M3 выбран как открытая мультиязычная embedding-модель с хорошей поддержкой русского языка и длинных текстов. Для новостей это важно: короткие модели могут обрезать существенную часть материала.

OpenAI embeddings я не использовал, потому что хотел локальное, воспроизводимое и потенциально on-premise решение без зависимости от внешнего API и стоимости каждого прогона.

Короткий ответ:

BGE-M3 дал хороший компромисс: русский язык, длинный контекст, качество эмбедингов и возможность локального запуска.

2. Датасет и разметка

Ручная golden-выборка небольшая — около 120 новостей. Она использовалась для проверки качества.

Для расширения обучения использовалась более крупная LLM-разметка как silver dataset. Это не заменяет полноценную экспертную разметку, но подходит для учебного прототипа и проверки технической гипотезы.

Ключевое ограничение:

Я не считаю текущую оценку финальной промышленной валидацией. Главный следующий шаг — расширить ручную разметку до нескольких тысяч новостей и проверить модель на свежих доменных данных.

3. Что такое сюжет?

Сюжет — это группа публикаций об одном событии или развитии события в ограниченном временном окне.

Это не широкая тема вроде “экономика” или “спорт”, а конкретный инфоповод: например, “ЦБ поднял ключевую ставку” или “компания объявила о сделке”.

Технически:

- вершины графа — новости;
 - рёбра — семантическая близость выше порога;
 - временное окно ограничивает склейку старых и новых событий;
 - компоненты связности считаются сюжетами.
-

4. Число кластеров и выбросы

Число кластеров не задаётся заранее. Оно динамическое: зависит от поступившего потока новостей, их близости и временного окна.

Одиночные новости остаются singleton-кластерами. Для новостного потока это нормально: не каждая публикация имеет дубли или продолжение.

5. False merge

Важно различать два порога:

- порог близости — параметр алгоритма кластеризации;
- целевой порог качества false merge $\leq 10\text{--}15\%$ — продуктовая граница приемлемости.

False merge означает ошибочную склейку разных событий в один сюжет. Это опасно для аналитика, поэтому метрика отдельно контролируется.

Текущий результат:

False merge rate 1.89% — ниже целевого порога 10–15%, значит по этому критерию MVP проходит минимальный уровень качества.

6. Модель значимости / новизны

Модель новизны — CatBoost-классификатор на табличных признаках, рассчитанных относительно прошлых новостей сюжета.

Важный принцип:

Я использовал только прошлый контекст, чтобы не было заглядывания в будущее.

Входные признаки включают:

- признаки текущей новости;
 - расстояние до предыдущих новостей сюжета;
 - признаки ближайшего прошлого кластера;
 - временные признаки;
 - контекст сюжета, доступный на момент публикации.
-

7. Почему высокий recall значимых обновлений?

Значимость новости частично субъективна, поэтому модель не должна быть единственным источником истины.

Я сознательно сдвигал баланс в сторону recall:

Для аналитика опаснее скрыть важное обновление, чем показать спорную новость на ручную проверку.

Пограничные случаи отображаются в UI как менее уверенные, а редактор может вручную исправить метку.

8. Почему RabbitMQ + Celery?

Асинхронная очередь нужна, чтобы UI не блокировался при тяжёлой обработке больших CSV и чтобы можно было масштабировать ML-воркеры.

Плюсы:

- пользователь продолжает работать;
- большие импорты не блокируют API;
- можно запускать несколько worker/model-service;
- сбои изолируются от UI.

Компромиссы:

- архитектура сложнее;
- нужны статусы задач;
- нужны retry, мониторинг и идемпотентность.

9. Не теряются ли задачи?

В очередь передаются id новостей, а не сами большие данные. Состояние задачи хранится в БД. Результат воркер записывает транзакционно.

Аккуратный ответ:

В текущей архитектуре риск потери снижен: если воркер падает до подтверждения задачи, RabbitMQ может вернуть её в очередь. Для production-версии я бы дополнительно усилил retry-policy, dead-letter queue и идемпотентность операций.

10. Почему PostgreSQL + pgvector, а не отдельная vector DB?

Для MVP pgvector даёт хороший компромисс: одна БД хранит и бизнес-сущности, и векторы, есть транзакции, SQL и простое развёртывание.

Специализированная векторная БД может понадобиться при росте объёмов, но на этом этапе она усложнила бы архитектуру без очевидной пользы.

Короткий ответ:

PostgreSQL + pgvector — проще, дешевле и достаточно для MVP. Если объём вырастет, можно перейти к специализированной векторной БД или гибридной архитектуре.

11. Производительность и память

По текущим benchmark-ориентирам:

- GPU RTX 4070;
- incremental: около 14 новостей/сек;
- full: около 44 новостей/сек;
- CPU заметно медленнее;
- CPU-воркеры масштабируются хуже GPU;
- 100 000 новостей нужно обрабатывать пачками через очередь.

Важно добавить в benchmark:

- peak RAM;
- peak VRAM;
- среднее потребление RAM/VRAM;
- размер батча;
- режим обработки: full / incremental;
- количество новостей: 10k / 50k / 100k, если успею.

Формулировка:

Следующий замер, который я добавлю в benchmark, — потребление RAM и VRAM. При больших CSV ограничением может стать не только скорость, но и память, поэтому batch-обработка нужна не только против timeout, но и для контроля ресурсов.

12. Почему клиент не просто использует ChatGPT?

ChatGPT полезен как разовый помощник, но SNN решает другую задачу: это системный workflow поверх базы новостей.

Отличия SNN:

- хранит новостную базу;
- группирует публикации в сюжеты;
- выделяет смысловую новизну;
- поддерживает семантический поиск;
- даёт роли и редакторский workflow;
- позволяет вручную исправлять метки;
- может разворачиваться локально;
- качество можно измерять метриками.

Короткий ответ:

ChatGPT — это разовый помощник. Semantic News Novelty — это рабочий процесс для регулярной обработки новостного потока.

13. Цена

Цена 100–200 долларов в месяц — это не финальный прайс, а стартовая гипотеза для пилота.

Логика цены — через экономию времени аналитика:

Если сервис экономит хотя бы 5–10 часов ручной вычитки в месяц, для малого агентства такая подписка уже может окупаться.

Позиционирование:

- дешевле и уже по задаче, чем full-cycle enterprise-платформы;
- больше контроля, чем разовые скрипты или ручная работа с LLM;
- подходит для локального/on-premise запуска на оборудовании клиента.

Короткий ответ:

Финальная цена должна проверяться через интервью и пилоты, но стартовая гипотеза — 100–200 долларов в месяц за инстанс или подписку для малой команды.

14. Первый клиент

Первый целевой клиент — малое или среднее аналитическое агентство либо аналитическое подразделение, которое готовит обзоры по открытым источникам, но не имеет собственной ML-команды.

Как искать:

- профильные агентства;
- аналитические подразделения компаний;
- профессиональные сообщества аналитиков;
- личные контакты;
- пилот на архивном или текущем новостном потоке клиента.

Короткий ответ:

Личная боль помогла сформулировать идею, но для проверки продукта нужен внешний пилот.

15. KPI на полгода

Главный KPI — проверить качество и ценность на более надёжных данных и реальных пользователях.

Три направления:

1. Данные и качество:
2. расширить ручную разметку до нескольких тысяч новостей;
3. подтвердить Pairwise F1 около 0.90+ на новой выборке;
4. амбициозная цель — приблизиться к 0.95;
5. сохранить высокий recall значимых обновлений.
6. Пилоты:
7. провести 2–3 тестирования или пилота с реальными аналитиками/компаниями;
8. собрать обратную связь.
9. Продуктовый эффект:
10. измерить, сокращается ли ручная вычитка;
11. понять, ускоряет ли сервис подготовку структуры обзора;
12. сформировать список доработок для перехода от MVP к пилотному продукту.

Короткий ответ:

Через полгода успех — это не просто новые фичи, а проверка гипотезы на свежих данных и реальных аналитиках.